

Apache Flink 1.9.0 特性解读

Flink China 北京站 Meetup - 2019年06月29日



About us

• 杨克特(鲁尼)

- Apache FlinkCommitter
- 目前在阿里巴巴负 责 Blink SQL 引擎

● 戴资力 (Gordon)

Ververica

- Apache Flink PMC
- Software Engineer @



Apache Flink 开源社区共同努力的成果

所有新版本释出的功能与改进,

绝非单一团队 / 个人的努力而来,



而是全体社区的数位成员无私贡献的成果





CONTENT 目录 >>

- 01 / Apache Flink 1.9.0 特性解读
 - 架构改动
 - Table API & SQL
 - Runtime & Core
 - 生态

02/ 未来版本计划



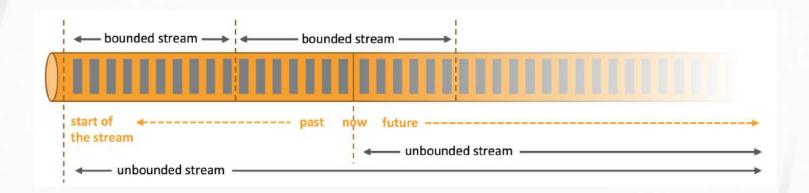
01

架构改动

Architecture Changes



Flink 的设计理念

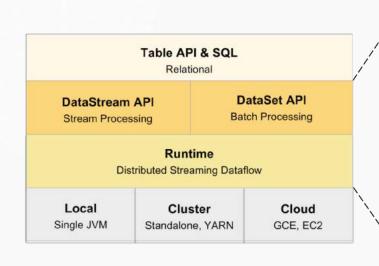


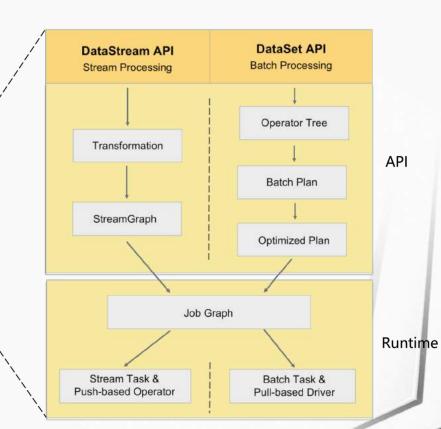
Continuous processing of unbounded data streams as *core abstraction*,

Batch as a *special case* of streaming



Flink 架构







存在的问题

• 从用户角度:

- 需要在两个底层API中进行选择
- 不同的语义、不同的connector支持、不同的错误恢复策略...
- Table API 也会受不同的底层API , 不同的connector等问题的影响

• 从开发者角度:

- 不同的翻译流程,不同的算子实现,不同的Task执行...
- 代码难以复用
- 两条独立的技术栈 -> 需要更多的人力 -> 功能开发变慢、性能提升变难 , bug变多



一个大胆的想法

既然批是流的一个特例,我们是否可以...?

DataStream API
Stream Processing

DataSet API
Batch Processing

搞定!



未来架构

DataStream

"Physical" Application API

Table API & SQL

Relational API

StreamTransformation DAG & StreamOperator

Runtime

Distributed Streaming Dataflow

Local

Single JVM

Cluster

Standalone, YARN

Cloud

GCE, EC2

端到端重构修改:

- Table API & SQL
- DataStream增加批处理
- 统一的DAG API
- 统一的算子 API
- 统一的Source API
- 网络传输架构
- 作业调度
- 错误处理

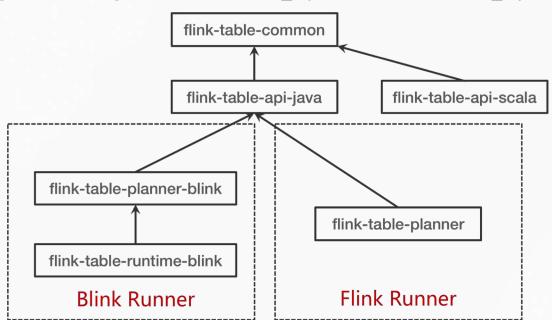
绿色:已启动 黄色:计划中



Table API & SQL 如何吃好这个螃蟹?

[FLIP-32] Restructure flink-table for future contributions

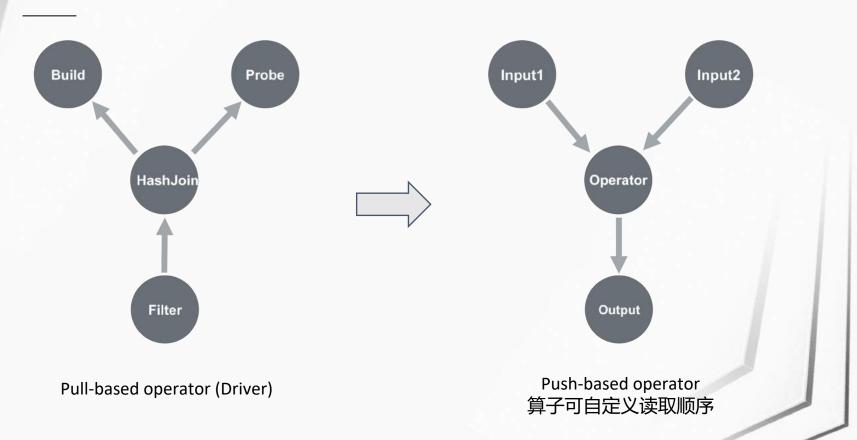
[FLINK-11439] INSERT INTO flink_sql SELECT * from blink_sql



- Table 模块进行拆分
- Table 支持多个 Runner,用户可自 行选择使用哪个 Runner
- Flink runner 保持原来的行为,继 续翻译到 DataStream/DataSet
- Blink runner 对接最新的 runtime
 架构,流批作业使用统一的 DAG
 和 StreamOperator 来描述
- 未来将只保留 Blink Runner



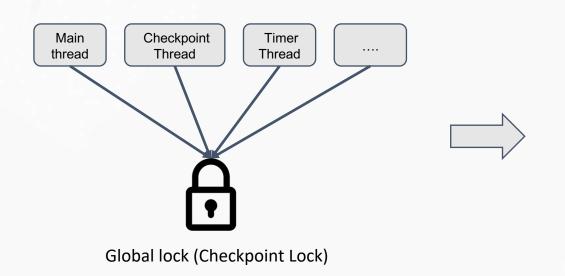
Selective Push Model Operator





Stream Task Mailbox Model

[FLINK-12477] Change threading-model in StreamTask to a mailbox-based approach







02

Table API & SQL



Table API & SQL 新特性预览

T











全新的 SQL 类型系统

DDL 初步支持 Table API 增强 统一的 Catalog API 更好的 Hive 兼容性

Blink Runner



全新的 SQL 类型系统

[FLIP-37] Rework of the Table API Type System

- 目前使用的 TypeInformation 的问题:
 - 和 SQL 的语义不一致 (比如Decimal没有精度信息)
 - 和物理存储格式绑定(TypeInformation绑定了TypeSerializer)
- 全新的 SQL 类型系统
 - 保持和 SQL 标准语义一致
 - 只包含纯粹的逻辑类型信息,可支持多种物理存储形式(比如 TIMESTAMP 可以用Long,java.sql.Timestamp,java.time.LocalDateTime 等形式来表示)
- 所有 SQL 类型: (绿色: 1.9完整支持,黄色: 1.9部分支持,红色: 1.9+)
 CHAR(n), VARCHAR(n), BOOLEAN, BINARY(n), VARBINARY(n),
 DECIMAL(p, s), NUMERIC, TINYINT, SMALLINT, INT, INTEGER, BIGINT, FLOAT, DOUBLE,
 DATE, TIME, TIMESTAMP, TIMESTAMP WITH TIMEZONE, TIMESTAMP WITH LOCAL TIMEZONE,
 INTERVAL YEAR, INTERVAL MONTH, INTERVAL DAY, INTERVAL HOUR, INTERVAL MINUTE, INTERVAL SECOND ARRAY, MULTISET, MAP, ROW, NULL, ANY, USER DEFINED TYPE



SQL DDL

```
CREATE TABLE kafka orders (
  order id VARCHAR,
  product VARCHAR,
  amount BIGINT,
  order ts TIMESTAMP,
                               Schema
  PRIMARY KEY (order id)
  proctime AS PROCTIME(),
  WATERMARK FOR order ts AS BOUNDED W ELAY '10' SECOND
) WITH (
                                                              ► Watermark (1.9?)
  connector='kafka',
  kafka.bootstrap.servers='localhost:9092',
  kafka.topic='orders',
  kafka.group.id='testGroup',
                                               定义了表的属性,包括存储类型,连
  kafka.startup-offset='earliest',
                                               接信息,读取范围,有界性等
  kafka.end-offset='none',
其他常用的DDL语句:
CREATE FUNCTION / CREATE VIEW
INSERT INTO / INSERT INTO PARTITION (hive dialect) / INSERT OVERWRITE (hive dialect)
```



从 SQL 文本自动区分流批计算(1.9+)

```
CREATE TABLE kafka orders (
  order id VARCHAR,
  product VARCHAR,
  amount BIGINT,
  order ts TIMESTAMP,
  PRIMARY KEY (order id)
  proctime AS PROCTIME(),
  WATERMARK FOR order ts AS BOUNDED WITH DELAY '10' SECOND
) WITH (
  connector='kafka',
  kafka.bootstrap.servers='localhost:9092',
  kafka.topic='orders',
  kafka.startup-offset='earliest',
  kafka.end-offset='none' 或 kafka.end-offset='2019-06-28 00:00:00'
SELECT product, TUMBLE START(order ts, INTERVAL '1' MINUTE), COUNT(*)
FROM kafka orders GROUP BY product, TUMBLE(order ts, INTERVAL '1' MINUTE);
更多讨论见:Ground Source Sink Concepts in Flink SQL
```



Table API 增强

- 更丰富的列操作API
 - o Table addColumns(Expression... fields);
 - o Table addOrReplaceColumns(Expression... fields);
 - Table renameColumns(Expression... fields);
 - Table dropColumns(Expression... fields);
- 更灵活的操作方法
 - o Table map(Expression mapFunction);
 - o Table flatMap(Expression tableFunction);
 - AggregatedTable aggregate(Expression aggregateFunction);
 - FlatAggregateTable flatAggregate(Expression tableAggregateFunction);



统一的 Catalog API

[FLIP-30] Unified Catalog APIs

统一的 Catalog API 的意义:

- 完整支持 DDL 的基础
- 可以使用不同的介质来存储meta信息(纯内存,文件,其他 meta 系统等)
- 便于和现有系统的集成(hive meta store, mysql)
- 使 Flink 不仅具备异构数据源的联合计算能力, 甚至提供跨数仓的联合计算

1.9 提供两种 Catalog 实现:

- InMemoryCatalog
- HiveCatalog(可以用在两种场景,一是将 Flink 的表存储到 HMS 中,二是以兼容的方式读写 Hive 元数据)



Hive 兼容性

总体计划: 1.9 支持和 Hive 相关的 DML(SELECT、INSERT),包括:

- 读取 Hive 数据表
 - 支持分区表和非分区表
 - 支持多种文件格式, text、orc、parquet等
- 以兼容的方式写 Hive 数据表
 - 支持分区表与非分区表,对于分区表支持静态分区与动态分区
- 支持读写 Hive 的复杂数据结构(除 UNION外)
- 支持在 Flink 中直接运行 Hive UDF,包括 GenericUDF, UDTF, UDAF

1.9+ 版本继续支持 Hive 的 DDL

更详细的信息不要错过:《Apache Flink-1.9与Hive的兼容性》



Blink Runner



数据结构 二进制化



更丰富的 内置函数



Minibatch Aggregation



多种解 热点手段



维表支持



TopN



高效的 流式去重



完整的 批处理支持



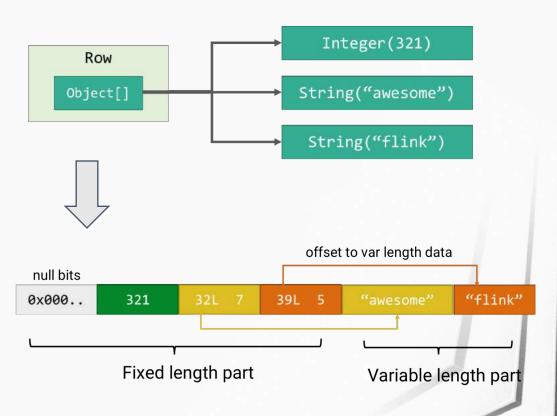
数据结构二进制化

旧数据结构:Row

- ➤ Java 对象的空间开销高
- ➤ 主类型的装箱和拆箱开销
- ➤ 昂贵的 hashCode() 和 (反)序列化

新数据结构:BinaryRow

- ➤ 完全基于二进制数据
- ➤ 与内存管理紧密结合, CPU 缓存友好
- ➤ 避免了大量反序列化开销
- ➤ 大幅提升流批作业性能

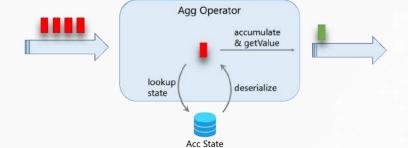




Minibatch Aggregation

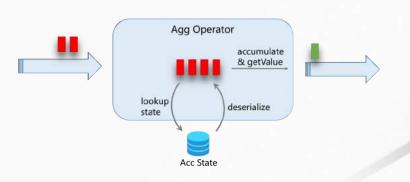
普通版本:

- ➤ 每一条消息都会读写 state
- ➤ 大量序列化/反序列化开销



Minibatch 版本:

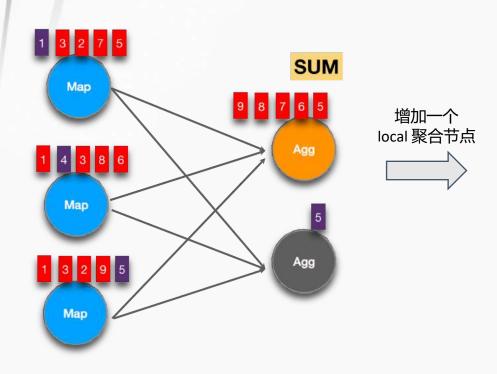
- ➤ 使用内存进行攒批
- ➤ 内存中即可聚合,减少 state 读写
- ➤ 输出数据少,下游压力降低
- ➤ 大幅提升吞吐

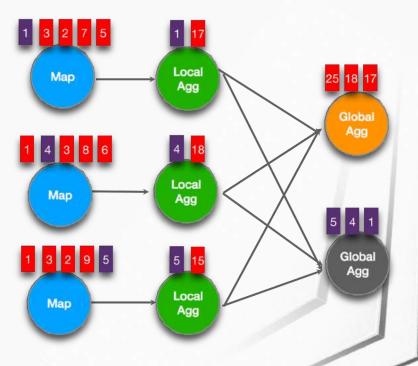




Local Global Agg 解决简单热点

SELECT COUNT(*) FROM T GROUP BY color







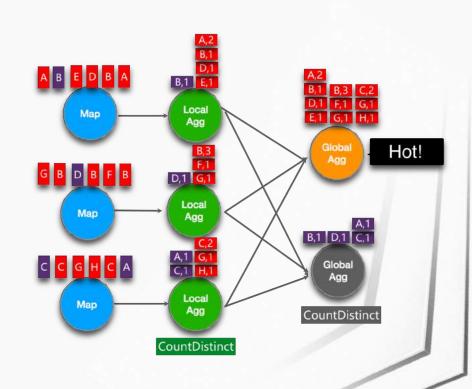
两层 Agg 改写解决复杂热点

SELECT color, COUNT(DISTINCT id) FROM T GROUP BY color

对于中间结果需要存储所有明细的agg(例如count distinct), 简单的 local - global 已经不能很好的解决热点问题

```
优化过程中进行
query 改写的操作
```

```
SELECT color, SUM(cnt)
FROM (
    SELECT color, COUNT(DISTINCT id) as cnt
    FROM T
    GROUP BY color, MOD(HASH_CODE(id), 1024)
)
GROUP BY color
```

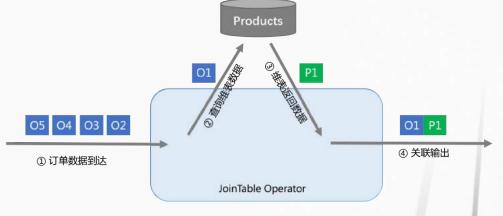




维表 join

CREATE TABLE mysql products (

```
product id VARCHAR,
 product_name VARCHAR,
  price DECIMAL(10, 2),
  PRIMARY KEY (product id)
) WITH (
  connector = 'mysql'
                                           05 04 03 02
);
                                             ① 订单数据到达
SELECT o.*, p.*
FROM kafka_orders AS o
JOIN mysql_products FOR SYSTEM_TIME AS OF o.proctime AS p
ON o.product id = p.product id
```





TopN 计算

例:计算每个类目中总销量排名前3的店铺

```
SELECT *
FROM (
   SELECT
    *,
    ROW_NUMBER() OVER (
        PARTITION BY category
        ORDER BY sales DESC) AS rownum
FROM shop_sales)
WHERE rownum <= 3</pre>
```

- 在流计算中,会识别这样的 query pattern 并优化成一个单独的算子
- 针对不同的细分场景,有多种不同的实现,优化器自动进行选择(比如只输出商家,不需要具体排名)

result			
category	shopId	sales	rownum
book	shop-43	89	1
book	shop-46	56	2
book	shop-58	43	3
fruit	shop-12	78	1
fruit	shop-44	67	2
fruit	shop-32	57	3



高效流式去重

数据中有PK,但是上游可能会重复发送,两种场景:

- 1. 上游由于重启或者其他原因发送完全重复数据,只有第一条对你有意义
- 2. 上游会持续不断的针对主键更新数据(比如上游是UpsertSink)

每个主键保留第一条数据:

```
SELECT parimary_key, a, b, c
FROM (
   SELECT
    *,
    ROW_NUMBER() OVER (
        PARTITION BY parimary_key
        ORDER BY proctime ASC) AS rownum
   FROM T)
WHERE rownum == 1
```

每个主键保留最后一条数据:

```
SELECT parimary_key, a, b, c
FROM (
   SELECT
    *,
    ROW_NUMBER() OVER (
        PARTITION BY parimary_key
        ORDER BY proctime DESC) AS rownum
FROM T)
WHERE rownum == 1
```

借鉴 TopN 的思想,识别 query pattern 后使用高效算子来实现



完整的批处理支持

- 功能
 - 基本功能完备
 - 支持多种 join 方式 (inner / left / right / full outer / semi / anti)
 - 完整支持几乎所有 over window
 - 支持子查询 (correlated / uncorrelated)
 - 高级分析函数支持 (grouping set, cube, rollup...)
- 稳定性
 - Runtime 进行了大量的稳定性优化(后面介绍)
 - Shuffle service 插件化

Flink 从 1.9 版本开始将成为传统批处理引擎的有力竞争者!



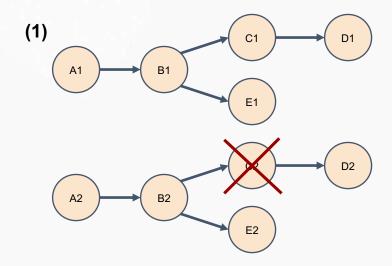
03

Runtime



[FLIP-1] Fine-grained recovery

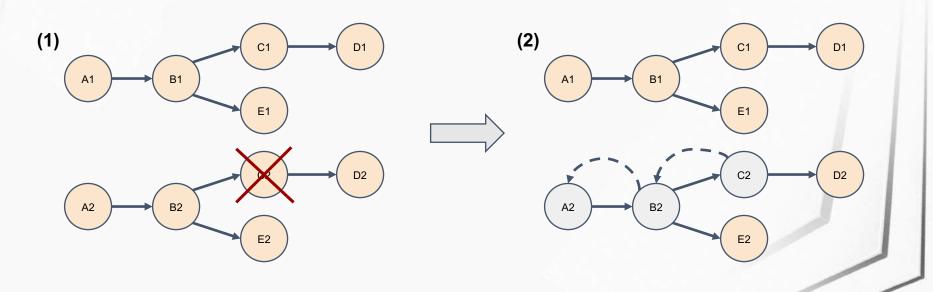
- 降低错误恢復所需花费时间 / IO 资源:
 - 错误发生时,只需局部重启与错误的 Task 有依赖的部分





[FLIP-1] Fine-grained recovery

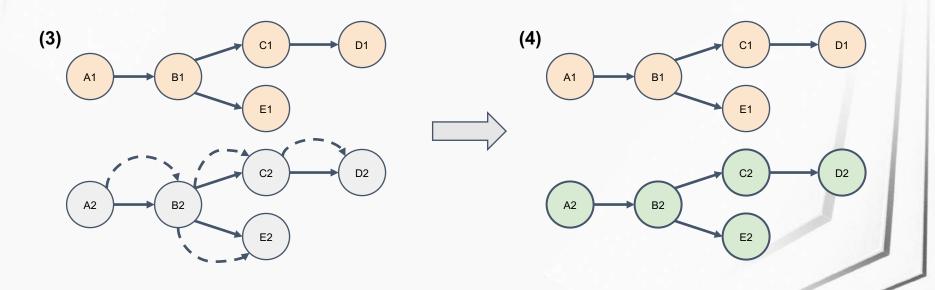
- 降低错误恢復所需花费时间 / IO 资源:
 - 错误发生时,只需局部重启与错误的 Task 有依赖的部分





[FLIP-1] Fine-grained recovery

- 降低错误恢復所需花费时间 / IO 资源:
 - 错误发生时,只需局部重启与错误的 Task 有依赖的部分



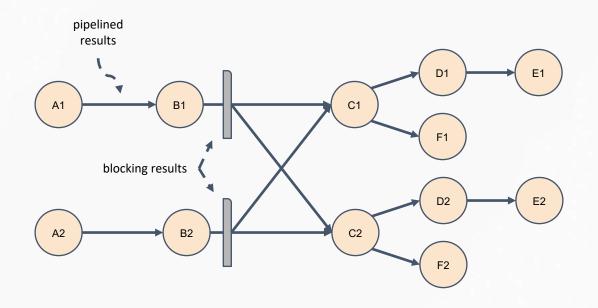


- 现有支援的限制:
 - 对于流式应用 -
 - 只对于 Embarrasingly Parallel (无 shuffling) 之应用有优化效果
 - 大部分流式应用算子间皆是 all-to-all 依赖关係, 且皆为 pipeline 计算



- 现有支援的限制:
 - 对于流式应用 -
 - 只对于 Embarrasingly Parallel (无 shuffling) 之应用有优化效果
 - 大部分流式应用算子间皆是 all-to-all 依赖关係,且皆为 pipeline 计算
 - 对于批次应用 -
 - 虽然算子也大多是 all-to-all 依赖关係, 但部分的中介结果为 blocking intermediate results,而非 pipelined
 - 可以利用此特性来缩减错误发生时执行 DAG 所需重启的范围



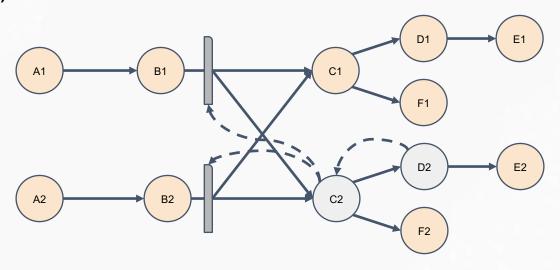




(1)

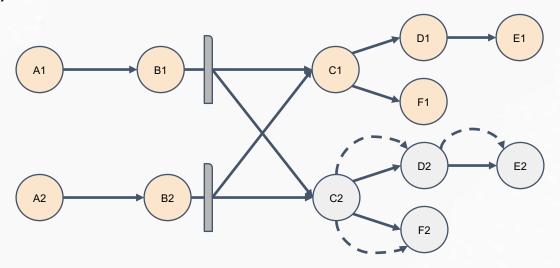


(2)



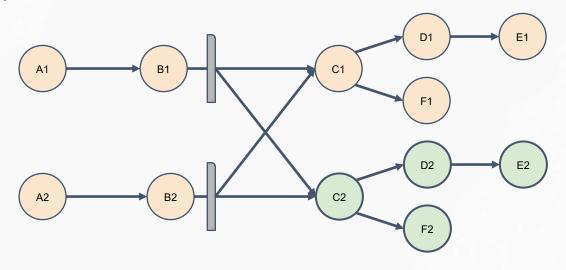


(3)





(4)





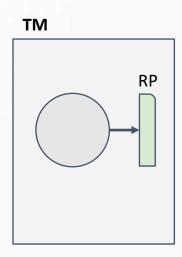
- 对于 runtime 的需求:
 - Intermediate result partitions (简称 RP)需支援重複消费
 - 若无法重複消费 RP,没办法更进一步缩减 DAG 所需重启的范围
 - <= 1.8: Task 结束运算后,产生的 RP 被下游算子消费一次后即被释出
 - 需集中化维护跨所有 TM 中所有 RP 的全域观
 - 拥有所有 RP 全域观,才能判断哪些 task 的产出 RP 仍存在, 决策无需重启的 task
 - ⇒ 需重构 RP 的生命週期管理,集中化管控



[FLIP-31] Pluggable Shuffle Manager

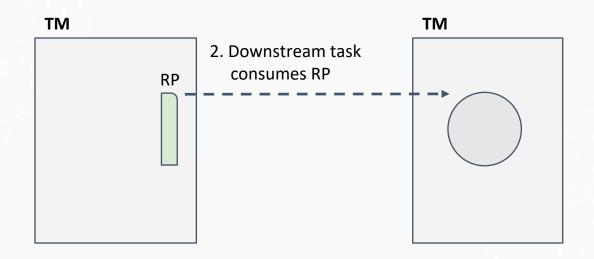
- 解决问题:
 - 重构 Result Partitions (RP) 生命週期,集中化管控
 - 使单一 RP 能够被重複消费
 - 方便 scheduler 查询仍存在的 RP 以决策错误发生需重启的 task
 - 解耦 TM 需同时负责产生 RP 与传输 RP (Shuffle) 之职责
 - 使 TM 能够在 Task 结束运算产生完 RP 后就提早释出运算资源
 - 方便扩增不同 shuffle / RP 储存的实现
 - 外部 shuffle service, 如 YARN external shuffle service
 - 将 RP 储存到 external storage,以脱离 job 的生命週期供跨 job 使用



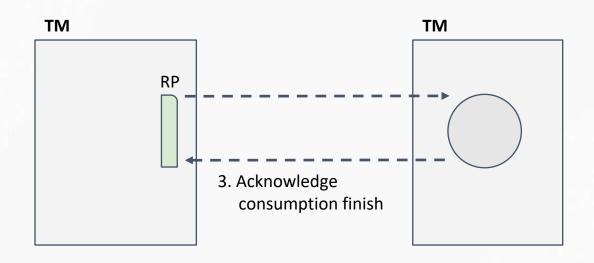


1. Producing task creates internal shuffle service (Netty) and generates RP

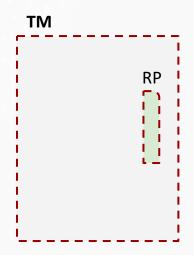




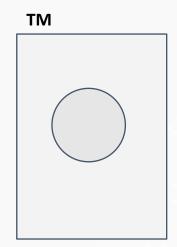




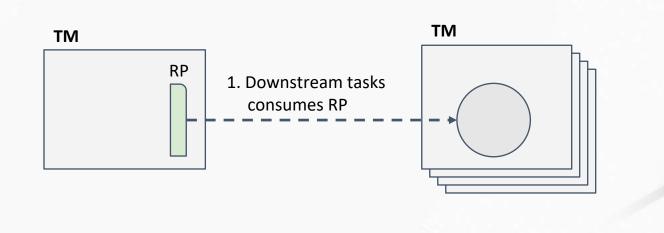




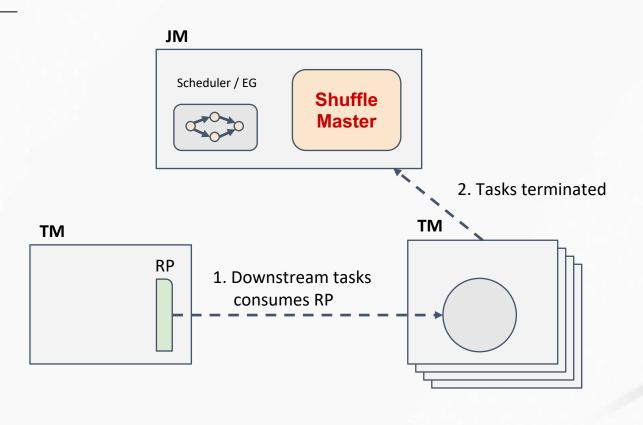
4. Release RP + task executor



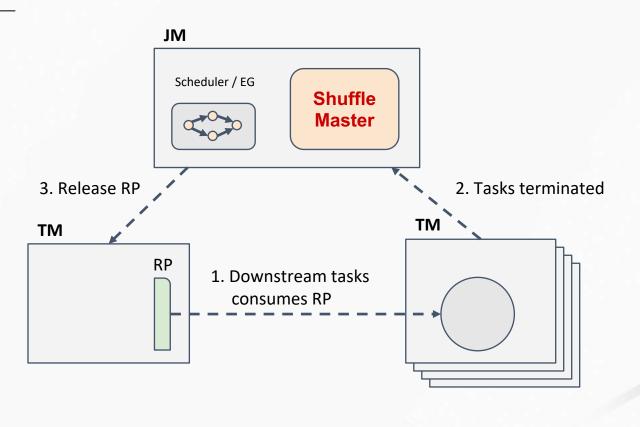












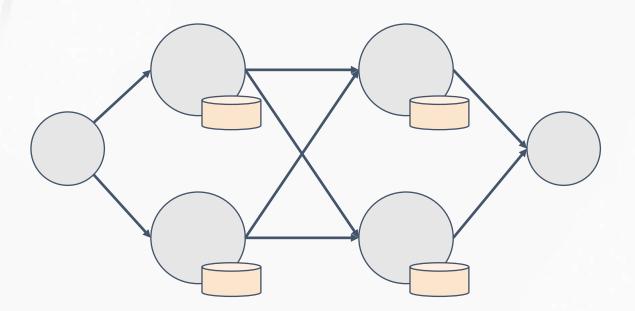


04

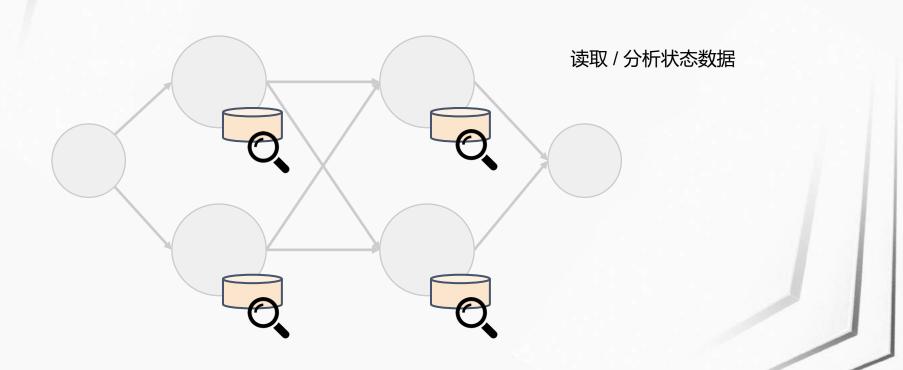
生态

Ecosystem

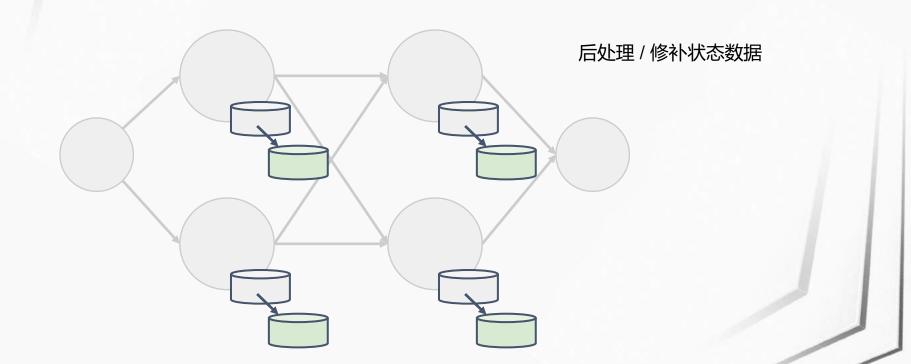




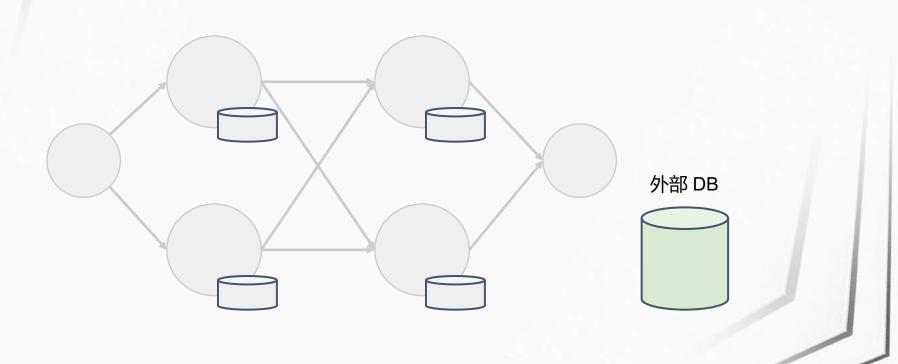




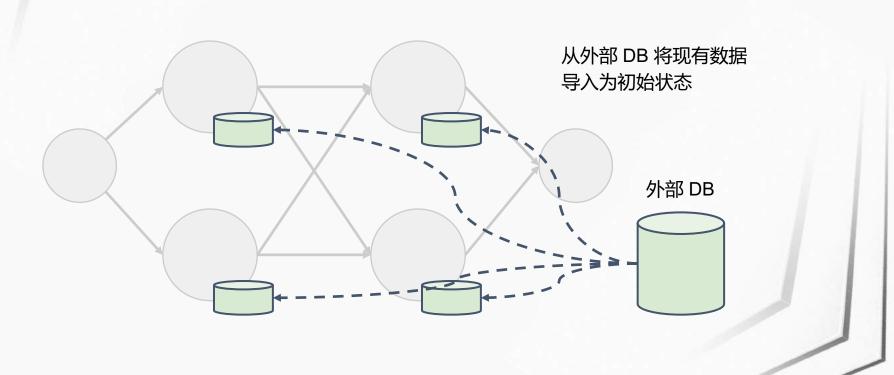














- 从用户角度:
 - 增加 Flink 流式应用内部状态的可及性
 - 修补 / 迁移状态数据更容易 , 不需要回放 source 讯息储列
 - 直接引入现有外部数据成为流式应用初始状态
- 从开发者角度:
 - 减少核心代码中用于应付状态多版本间格式相容的读写逻辑



```
ExecutionEnvironment env = ExecutionEnvironment.getExecutionEnvironment();
ExistingSavepoint savepoint = Savepoint.load("/savepoint/path", env);
DataSet<MyState> loadedKeyedState = savepoint
    .readKeyedState("operatorUid", new MyKeyedStateReaderFunction());
DataSet<MyProcessedState> processedKeyedState = loadedKeyedState
BootstrapTransformation<MyProcessedState> bootstrapOperator = OperatorTransformation
    .bootstrapWith(processedKeyedState)
    .transform(new MyStateBootstrapFunction());
savepoint
    .withOperator("operatorUid", bootstrapOperator)
    .write("/new/savepoint/path");
```



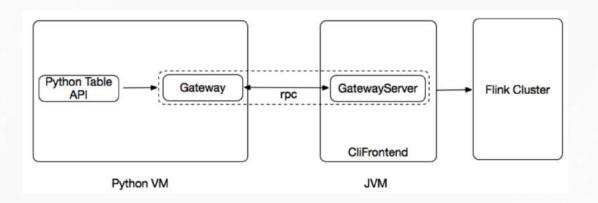
Python Table API

[FLIP-38] Python Table API

- 1.9.0 版 PyFlink 主要功能:
 - 架构上,利用 Py4j 建立了 PythonVM 与 JVM 的通讯
 - 支援所有 Java Table API 固有的功能 (除了 UDF / UDTF / UDAF)
 - 直接透过原有 CLI 提交 Python Table API 应用
 - 支持互动式开发 Interactive Shell



Python Table API - 架构设计



- 目标:直接基于现有的 Java Table API 上实现 Python API
 - Python Table API 只需定义 API 介面
 - 透过 rpc 去直接呼叫对应的 Java Table API
 - e.g. TableEnvironment / Table / TableSink, 等皆会有对应的 Python wrapper



Python Table API - 范例代码

```
from pyflink.dataset import ExecutionEnvironment
from pyflink.table import BatchTableEnvironment, TableConfig
from pyflink.table.descriptors import FileSystem, OldCsv, Schema
from pyflink.table.types import DataTypes
def word count():
   t config = TableConfig()
   env = ExecutionEnvironment.get execution environment()
   t env = BatchTableEnvironment.create(env, t config)
   elements = [(word, 1) for word in content.split(" ")]
   t env.from elements(elements, ["word", "count"]) \
        .group by("word") \
        .select("word, count(1) as count") \
        .insert into("Results")
   env.execute()
```



Python Table API

• 沿用现有的 Flink CLI 做应用提交

```
./bin/flink run \
    -py examples/python/table/batch/word_count.py \
    -j <path/to/flink-table.jar>
```

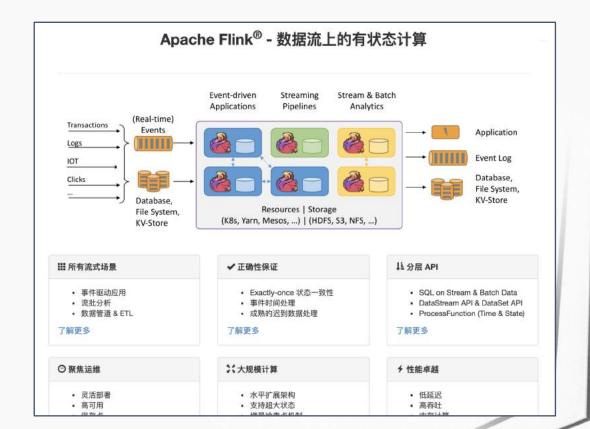
● 支援 Interactive Shell

```
./bin/pyflink-shell.sh [local|remote]
```



官方网页/文档中文翻译

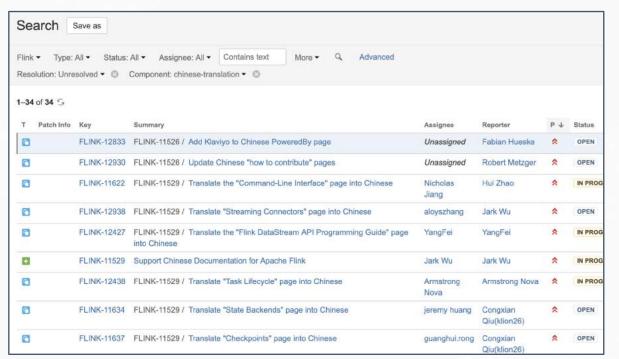






官方网页/文档中文翻译

所有文档翻译相关任务项目:點我





官方中文使用者邮件列表

Apache Flink 中文用户邮件列表

This forum is an archive for the mailing list **user-zh@flink.apache.org** (<u>more options</u>) Messages posted here will be sent to this mailing list.

Apache Flink 中文用户部件列表

Q.

Topics (20)	Replies	Last Post	Views
Flink1.8+Hadoop3.1.2 编译问题 by CHENJIE	3	Jun 28 by CHENJIE	4
checkpoint stage size的问题 by ReignsDYL	6	Jun 28 by CHENJIE	49
Flink如何实现Job间的协同联系?_ by 徐涛	3	Jun 28 by Hequn Cheng	18
Flink 窗口触发疑问 by 雷水鱼	0	<u>Jun 27</u> by 雷水鱼	4
Re: checkpoint stage size的问题 by ReignsDYL	0	Jun 26 by ReignsDYL	7
来自小乐的邮件 by 小乐	0	<u>Jun 26</u> by 小乐	3
关于使用Flink建设基于CDC方式的OGG数据器 by 應门小师兄	0	<u>Jun 26</u> by 唐门小师兄	6
blink 版本 消费kafka 看不到group id by 雷水鱼	3	Jun 25 by Blao Liu	8
你好!_ by 杨胜松(鼓翅)	1	Jun 25 by Biao Liu	7
flink filesystem 1.7.2 on Hadoop 2.7 BucketingSink.reflectTruncat().有写入很多小文件到hdfs的风险 by 巫旭阳	2	Jun 24 by 巫旭阳	2
Flink程序长期运行后报错退出 PartitionRequestQueue - Encountered error while consuming partitions by 罗学焕/予之	1	Jun 24 by Blao Liu	15
Flink tos 遠度问题 by halbin	1	Jun 24 by Biao Liu	14
flink连续窗口 by 残避2008	1	Jun 24 by Biao Liu	7
EventTimeTrigger達码求帮忙解读,求各位大佬帮帮忙,不胜感激 by 840124434	3	Jun 24 by Shi Quan	12
Flink任务资源动态规划 by 15904502343@163.com	1	Jun 21 by 田志声	5
为何会报"Window can only be defined over a time attribute column."?? by Chennet Steven	1	Jun 21 by Chennet Steven	1



官方中文使用者邮件列表

- 中文邮件列表订阅方式:
 - o 寄一封邮件到 user-zh-subscribe@flink.apache.org
 - o 系统会自动寄发订阅确认邮件
 - o 直接回复该邮件,即可订阅
- 订阅成功后将收到 Flink 中文邮件列表的所有消息,提问,回复等
- 尚未订阅的人**无法**对邮件列表发送邮件
- 订阅指南视频: https://www.bilibili.com/video/av57076677/



05

未来版本计划

Future Plan



未来版本计划

SQL

- o 继续完善 Type System 和 DDL
- Ground Source Sink Concepts in Flink SQL

Runtime

- o DataStream 增加批处理功能
- [FLIP-27] Unified runtime source API
- [FLIP-41] Unify Binary format for Keyed State
- Disk-spilling heap backend

生态

- o 原生支持 Protobuf / Thrift 等序列化格式
- o 支持 Python UDF
- o 继续完善 ML 算法库
- o 继续完善 Hive 兼容性



THANKS

